

各位老师好，我是周子轩，我的毕业设计题目是“基于大语言模型的社交媒体青少年生殖健康评论分类分析与问答生成研究”。指导老师是黄若尘老师。

3 首先，是课题概述 4 关于**本研究的背景**。青少年生殖健康问题在全球范围内都十分严峻。世界卫生组织和《柳叶刀》的报告都明确指出，相关问题存在被长期忽视的情况。中国也面临同样的挑战，包括青少年非意愿妊娠、人工流产及性病感染率**持续上升**的严峻现状。不论是全球视角还是中国的现状，都反映出一个核心矛盾：那就是青少年日益严峻的健康风险与当前**亟需加强**的生殖健康教育之间的**鸿沟**。

5 **传统教育**面临文化敏感性高、覆盖面不足和效果不佳的困境，于是青少年转向了 B 站这类更便捷、匿名的社交平台，为我们提供了一个**洞察**他们**真实困惑**的天然“问题语料库”。但这个库藏的内容良莠不齐，因此，如何从海量、非结构化的文本中**挖掘价值**，并转化为科学、规范的知识资源，成为关键挑战。

6 **研究的意义**，首先在于深入 B 站，从海量真实评论中挖掘出青少年最真实的健康困惑。

接着，利用大模型，将这些零散的问题转化成一个科学、规范的高质量问答数据集。

最终，用这个数据集微调大模型，真正实现从**真实需求**到**智能服务**的闭环。

7 **国内外的研究都存在断层**，分析用户行为的研究多停留在现象描述，而探索 AI 应用的研究又较少扎根于社交媒体海量的、真实的用户话语体系。

本研究的创新在于系统性地将大语言模型作为核心工具，打通从“非结构化用户评论”到“高质量的结构化问答数据集”的全链路，填补了当前研究的空白。

9 本研究有**三个目标**：首先，是识别并归类出青少年最核心的健康问题。其次，创建一个科学、高质量的专业问答数据集。最终目标是基于该数据集，微调并验证一个性能显著提升的 AI 模型。

10 **研究内容**主要分四项：第一，从 B 站海量评论中，筛选出用户的真实问题。第二，对问题进行分类和定量分析，揭示青少年的关注焦点。第三，利用大模型生成高质量的问答对，构建一个标准数据集。第四，用该数据集去微调模型，并评估其回答专业问题的能力。

11 **研究进展**的第一部分是数据获取。以 B 站平台作为数据源，时间覆盖从 2016 年至 2024 年近 8 年。为确保数据的代表性，仅筛选播放量超过 10 万次的热门视频。采集内容不仅包含视频的结构化元数据，更获取了全量的非结构化文本，即评论和弹幕，作为挖掘用户真实需求的核心素材。

12 目前，研究共纳入了 743 个核心视频，累计覆盖了 4.86 亿次观看，并收集了 176 万条评论与弹幕数据。采集到的丰富的数据量和多维度的字段信息，为后续的模型训练和深度分析提供了坚实基础。

13 研究构建了一个包含 13 个主题的分类框架，并发现了一个关键现象：内容供给存在显著的不均衡性。超过一半的内容集中在“安全套”和“基础教育”这两大类；而像“女性主导避孕”或“深层次生殖疾病”等具体话题，内容占比极低。由此可见主流视频未能覆盖的深层需求，往往隐藏在用户的提问和评论中，这正是研究下一步挖掘的重点。

14 这张图是 13 个主题的视频数量分布

15 关于**问答数据集的构建工作**。从真实的原始提问出发，利用大模型进行规范化改写并生成初步答案，最后必须经过人工修订与专家审核入库。该数据集的核心价值在于源于真实场景且内容科学可靠，并将碎片化的语料转化为了结构化的医学知识。

16 如图是几个规范化问答的案例

18 遇到的问题及解决方案。

19 在具体实施中，研究首先遇到了**数据清洗**的挑战。社交媒体评论充斥着大量的网络黑话、谐音梗和表情符号，这给机器识别**真问题**带来了巨大干扰。研究通过**自动化脚本+人工复核**的组合策略，配合人工抽样检查，在迭代中逐步解决了非规范表达的识别难题，保证了问题提取的准确率。

20 其二是**模型幻觉问题**。通用大模型在生成医学建议时，可能会出现事实性错误或模棱两可的回答，导致不可接受的风险。通过邀请医学背景的专家，对 AI 生成的每一条答案进行事实核查和科学性把关，确保最终数据集具备医学层面的权威性与严谨性

21 关于计算资源的限制，研究申请并利用了学院的高性能计算平台，同时通过代码优化和分批处理策略，保障了项目在有限资源下的顺利推进。

23 下一阶段的研究计划包括：青少年生殖健康问题分类分析研究，开源大语言模型的指令微调、24 模型性能的综合评估以及论文撰写。