

南京医科大学本科生毕业论文（设计）中期检查表

学生姓名	周子轩	学号	22250117	学院	生物医学工程与信息学院	专业	智能医学工程
指导教师	黄若尘	职称	讲师	工作单位	南京医科大学生物医学工程与信息学院		
毕业论文（设计）题目：		基于大语言模型的社交媒体青少年生殖健康评论分类分析与问答生成研究					

1 毕业论文（设计）计划进度安排

本项目自启动以来，严格按照预定计划有序推进。在项目初期，主要完成了相关文献的调研与梳理，确立了基于大语言模型挖掘社交媒体青少年生殖健康数据的研究思路，并完成了开题报告的撰写与答辩。随后进入数据采集与处理阶段，利用分布式爬虫技术构建了针对 Bilibili 平台的生殖健康视频数据集，并完成了数据的清洗、去重及隐私脱敏工作。在此基础上，项目中期重点开展了基于大语言模型的情感分析与用户互动行为研究，并初步构建了包含原始提问、规范化问题及专家级回答的青少年生殖健康问答数据集（Q&A Dataset）。

针对下一阶段，计划首先利用已构建的问答数据集，深入开展青少年生殖健康问题的分类分析研究，挖掘不同主题下的用户核心诉求与认知盲区。随后，将进入模型训练的核心环节，选用开源大语言模型（如 Qwen 系列）进行指令微调，以提升模型在生殖健康领域的问答准确性与共情能力，并设计多维度的评估指标对模型性能进行验证。最后，预计在答辩前一个月完成所有实验数据的整理与分析，撰写毕业论文定稿，制作答辩演示文稿，为最终的毕业答辩做好充分准备。

2 已完成情况、存在的主要问题及拟解决措施

2.1 已完成情况

截止目前，毕业设计的研究工作已取得阶段性重要成果。在数据层面，已成功采集并筛选出 2016 年至 2024 年间 Bilibili 平台上的 743 个高质量生殖健康视频，建立了包含 4.86 亿次观看数据、1231 万次点赞以及约 176 万条评论与弹幕的综合数据库。在分析层面，完成了对视频内容、UP 主背景及用户参与度的描述性统计，并利用 Qwen2.5-32B 大模型对用户评论进行了情感分类，揭示了青少年在“人工流产”等敏感话题上显著的负面情绪倾向，以及在“避孕科普”内容上的知识渴求。此外，已初步完成了高质量问答数据集的构建工作，实现了从非结构化用户评论到结构化医学问答对的转化，为后续模型微调奠定了坚实基础。

2.2 存在的主要问题

尽管项目进展顺利，但在研究过程中仍面临若干具体挑战。

关于数据质量，社交媒体文本具有高度非结构化特征，充斥着大量网络俚语、缩写及非规范表达，导致传统的分词与清洗工具处理效果受限，影响了后续分析的精准度。

在数据分布方面，现有的生殖健康主题数据存在一定的不均衡性，例如基础避孕知识的讨论较多，而关于新型避孕方式或特定生殖疾病的讨论相对匮乏，这可能影响模型在长尾问题上的泛化能力。

大语言模型在医学垂直领域的应用，存在潜在的“幻觉”风险，即可能生成看似合理但医学事实错误的回答，且全量微调模型对算力资源的要求较高，给实验环境带来了一定压力。

2.3 拟解决措施

针对上述问题，拟在下一阶段采取以下针对性解决策略。

对于文本规范化难题，将利用大语言模型强大的语义理解能力辅助数据清洗，并结合人工抽检机制，建立更精细的预处理流程以提升语料质量。

针对数据分布不均的问题，计划采用数据增强技术扩充稀缺类别的样本量，并考虑引入权威医学指南或教科书数据作为外部知识补充，以平衡训练数据的分布。

而在模型优化与可靠性方面，将采用 LoRA (Low-Rank Adaptation) 等参数高效微调技术以降低算力门槛，提高训练效率；同时，在模型推理阶段引入检索增强生成 (Retrieval Augmented Generation, RAG) 技术或专家知识库校验机制，将模型生成内容限制在可靠的医学知识范围内，从而有效抑制“幻觉”现象，确保生成内容的医学准确性与安全性。

评语：(包括进度、质量、出勤、纪律等) 	
---	--

指导教师签字：_____
年 月 日

年 月 日

系意见：

系主任签字： 年 月 日

学院意见：	
院长签字：	 年 月 日

年 月 日

年 月 日

备注:	
-----	--

教务处制表