



开题报告

答辩时间: 2025 年 9 月 18 日

1 课题的意义、国内外研究概况、应用前景等

生殖健康是青少年身心健康的重要基础之一，然而有关问题在全球范围内日益严峻。有权威报告指出，全球青少年生殖健康长期未得到足够重视，许多国家在性教育覆盖、避孕服务和意外妊娠防控方面存在显著缺口^[1]。世界卫生组织的最新数据显示，仅在 2019 年，低收入和中等收入国家的 15 至 19 岁女性中就估计有 2100 万例怀孕，其中约半数为非意愿妊娠，这导致了大量的健康风险与社会问题^[2]。在中国，这一挑战同样突出。随着青春期提前和婚前性行为的增多，青少年因生殖健康知识缺乏而导致的非意愿妊娠、人工流产及性传播疾病感染率呈上升趋势^[3]。有研究指出，尽管中国总体成人 HIV 感染率下降，但 15-24 岁青少年人群的 HIV 发病率在 2008 至 2017 年间却增加了约五倍，淋病和梅毒等性病发病率也在上升^[4]。这些数据深刻反映出，当前青少年在性与生殖健康方面的知识和服务供给存在巨大缺口，亟需探索更有效的教育和信息传播路径，以改善青少年生殖健康状况。

1.1 研究意义

青少年生殖健康教育，是一个涵盖避孕知识、安全流产服务、性传播疾病预防，乃至情感教育和健康意识培养的综合性议题^[5]。尽管全球在女性健康领域取得了显著进展，但传统医疗保健与教育体系在满足青少年多样化、个性化且具有隐私性的生殖健康需求方面仍显乏力，尤其是在中国这样受传统观念影响较深的社会环境中，这种短板尤为突出^[6]。传统学校教育因其对生殖健康话题的敏感性，往往存在课程覆盖不足、内容陈旧、难以深入等问题，导致青少年在理解和应对生殖健康挑战时存在显著的知识与能力缺口^[7,8]。因此，探索面向青少年更易于接受、更具互动性且内容可靠的生殖健康信息传播渠道，成为当前公共卫生和教育领域亟待解决的重要课题。

互联网与社交媒体的迅猛发展，为青少年获取健康信息提供了全新的路径。数字平台的匿名性、便捷性和广泛的可及性，使其成为青少年在探寻避孕、性病防治等敏感话题时不可或缺的信息来源^[9]。已有研究证实，在线教育项目和移动健康应用等数字干预措施，在提升青少年性健康知识和促进行为改变方面具有显著效果^[10,11]。这些平台通过提供灵活、可扩展的传播方式，有效克服了传统健康服务在覆盖面和接受度上的局限，为青少年生殖健康教育开辟了新的可能性。

在中国，哔哩哔哩（Bilibili）作为深受“Z 世代”欢迎的视频分享平台，已成为青少年获取生殖健康信息的重要渠道。其庞大的年轻用户群体构成了一个独特的数字生态，用户生成内容（User-Generated Content, UGC）的广泛性为分析青少年健康需求、信息偏好及情感反应提供了丰富素材^[12]。然而，以往研究多集中于分析健康视频的传播效果或评估其内容质量，却较少关注到平台上海量用户评论、弹幕及回复中所蕴含的巨大价值。这些非正式的、口语化的用户互动，真实地反映了青少年在生殖健康领域的具体困惑、知识盲区和核心诉求。评论区和弹幕不仅是用户反馈情感的场所，更是一个自发的“问答社区”，青少年在此提出真实世界中难以启齿的问题，并寻求同伴的共鸣与解答^[13,14]。

与此同时，用户生成内容的质量参差不齐，充斥着大量未经证实甚至错误的信息，对缺乏辨别能力的青少年构成潜在风险^[15,16]。如何从这些海量、嘈杂、非结构化的用户评论中，挖掘出有价值的真实问题？如何将这些口语化、碎片化的提问，转化为规范、科学、可用于健康教育的标准化知识资源？这成为当前研究面临的核心挑战之一。

在此背景下，大语言模型（Large Language Model, LLM）等人工智能技术的崛起为解决上述问题提供了前所未有的机遇。LLM 在理解自然语言、文本生成和知识推理方面展现出强大能力，已在医疗问答、患者教育等领域显现出巨大潜力^[17]。已有研究表明，先进的 AI 模型在回答患者问题时，甚至能在同理心和信息丰富度上超越人类医生^[18]。

本研究的创新意义在于，尝试将大语言模型技术应用于 Bilibili 平台青少年生殖健康评论的分

析与转化。研究不再仅仅停留在对现有内容的被动分析，而是主动地将海量、真实的青少年评论与弹幕视为“问题语料库”。利用自然语言处理技术，从非结构化文本中自动识别、提取并分类青少年用户的真实健康问题，并借助大语言模型，将这些口语化、非正式的问题进行规范化重写，并生成科学、准确、易于理解的答案，从而构建国内首个源于社交媒体真实场景的青少年生殖健康问答数据集。在此基础上，对开源大语言模型进行领域微调，探索提升其在专业健康教育问答任务中性能的可能性。

从“用户真实问题”至“高质量结构化知识”再到“智能化问答服务”，研究成果不仅能揭示当代中国青少年在数字环境下的核心生殖健康诉求与知识缺口，为精准健康教育政策的制定提供数据支持，更能产出一个兼具科学性与实用性的高质量问答数据集，为优化数字健康平台内容、开发智能问答机器人、乃至推动我国青少年生殖健康教育事业的智能化发展提供坚实的科学依据和实践基础。

1.2 国内外研究概况

国内外在青少年生殖健康教育领域的研究均已认识到社交媒体和数字平台的巨大潜力与复杂挑战。国际研究起步较早，已从验证数字干预的有效性，逐步深入到分析用户生成内容的质量、挖掘用户真实需求，并开始探索利用大语言模型等前沿人工智能技术赋能健康传播。国内研究虽然起步稍晚，但近年来发展迅速，紧密结合本土社交媒体生态（如哔哩哔哩、抖音），在分析平台内容特征、用户互动模式及探索 AI 应用方面取得了显著进展。值得注意的是，无论是国内还是国外，将海量、非结构化的社交媒体用户评论系统性地转化为高质量、可用于模型微调的结构化问答知识资源，仍是一个亟待填补的研究空白，也为本研究提供了切入点。

1.2.1 国外研究概况

国外学术界对利用数字平台进行青少年生殖健康教育的研究已形成较为系统的体系。早期研究主要聚焦于证实社交媒体作为健康信息渠道的可行性与有效性。有系统性综述表明，全球青少年已广泛通过 YouTube、Facebook 等平台获取性与生殖健康知识，数字干预措施在提升其知识水平和改变健康行为方面展现出积极效果^[9,10]。这些研究为数字健康传播奠定了理论与实证基础。

随着研究的深入，相关学者开始关注数字平台传播内容的质量、文化适应性及潜在风险。研究发现，不同文化背景下，数字性教育的模式与效果差异显著，需要因地制宜地设计干预方案^[19,20]。同时，社交媒体上健康信息的质量良莠不齐，甚至充斥着大量误导性信息和谣言，对缺乏辨别能力的青少年造成严重消极影响^[15]。一项针对 TikTok 和 YouTube 上梅毒相关内容的最新研究发现，尽管 TikTok 的视频浏览量更高，但其内容的科学性远低于 YouTube，凸显了在不同平台进行内容质量监控与干预的紧迫性^[21]。

为了更深入地理解用户需求，研究视角逐渐从分析“传播了什么”转向挖掘“用户在问什么”。相关研究人员开始利用自然语言处理（Natural Language Processing, NLP）技术分析用户在社交媒体和健康论坛上留下的评论与提问。曾有研究针对卢旺达 YouTube 频道的用户评论进行分析，发现评论区已成为青少年提出疑问、分享经验和寻求情感支持的重要互动空间，其价值远超简单的内容反馈^[13]。更有研究团队致力于构建自动问答系统，通过机器学习模型对用户的医疗健康问题进行自动分类，以匹配更精准的答案，这证明了从海量用户生成内容中识别和归类健康问题在技术上是可行的^[22,23]。

近年来，大语言模型的突破性进展为健康教育领域带来了革命性的机遇。曾有权威综述指出，LLM 在健康咨询问答、生成个性化教育材料等方面展现出巨大潜力^[17]。一项广受关注的研究对比了医生与 ChatGPT 对社交媒体上患者提问的回答，结果显示 AI 的回答在同理心和信息丰富度方面甚至更胜一筹^[18]。亦有研究表明，最先进的 LLM（如 GPT-4）已具备通过美国执业医师资格考试的能力，证明其掌握了渊博的医学知识^[24]。

国外研究已经历了从渠道的有效性证实，到内容质量的评估，再到用户提问挖掘和前沿 AI 技术应用的演进。这些成果为本研究提供了重要的理论依据和方法参考。但值得一提的是，尽管已有研究利用 NLP 技术对用户问题进行分类，或评估 LLM 在问答任务中的表现，但鲜有研究将二者系统地结合起来，即利用 LLM 作为核心工具，将社交媒体上真实、海量、非正式的青少年评论，通过提取、分类、规范化和问答生成等一系列步骤，转化为可用于训练和优化 AI 模型的结构化、高质量数据集。这一方法论上的空白，为本研究留下了创新的空间。

1.2.2 国内研究概况

相较于国外，国内对青少年生殖健康问题的系统研究起步较晚。受限于传统观念，早期相关工作多以学校教育和公共卫生体系为主，内容相对保守，且多聚焦于基础知识的普及和传统健康观念的强化。21 世纪初，虽然中国政府已陆续出台了加强中小学生青春期卫生教育的政策，但受传统文化观念和 policy 限制，学校性与生殖健康教育在实际落实中仍面临敏感话题规避、课程覆盖不足等突出问题^[25]。多项全国性或区域性调查均揭露了严峻的现实：中国青少年生殖健康知识水平普遍偏低，知识及格率不高^[3,8]。这种线下教育的缺失，使得青少年日益转向互联网和社交媒体寻求答案。

跟随这一趋势，国内研究的重心也逐渐转向数字平台。有关研究发现，视频平台、微信公众号等已成为中学生获取性知识的主要渠道^[26]。针对抖音、哔哩哔哩（Bilibili）等热门平台的研究开始涌现。这些研究一方面肯定了短视频在健康科普传播中的巨大潜力，另一方面也揭示了其中突出的问题，如内容质量良莠不齐、信息“失真”与“失焦”、过度娱乐化和商业化等，这些都可能对青少年产生误导^[16,27]。可见，仅仅依赖平台自发生成的内容远不足以满足科学、严谨的健康教育需求。

为了更精准地把握青少年在数字平台上的信息需求与互动行为，一些研究开始采用大数据方法进行深入分析。一项针对 Bilibili 健康视频弹幕的研究极具启发性，该研究通过主题建模发现，观众在弹幕中不仅寻求知识，更在寻求情感支持和社交互动，而满足这些复合需求的视频往往能获得更高的播放量^[14]。这有力揭示了 Bilibili 等社区型平台的用户评论和弹幕，是承载青少年真实困惑、情感诉求和知识缺口的“富矿”，其价值远不仅限于简单的视频观看反馈。

国内在人工智能与健康交叉领域的研究也在迎头赶上。已有学者针对中文网络健康社区的用户提问进行分层分类研究，证明了利用 NLP 技术挖掘中文用户健康诉求的可行性^[28]。随着大语言模型的兴起，国内顶尖研究机构也推出了专注于中文医疗领域的垂域大模型（如“仲景（Zhongjing）”），通过专家反馈和真实医患对话进行微调，显著提升了模型在中文医学问答任务上的准确性和专业性^[29]。相关研究为本课题利用 LLM 处理中文生殖健康语料提供了宝贵的技术参考。

综上所述，国内研究已清晰地指出了传统教育的不足、青少年向线上转移的趋势，并深入到了对 Bilibili 等特定平台用户互动行为的分析，同时在 AI 医疗应用上取得初步成果。问题在于，现有研究仍存在明显断层：分析平台内容与用户行为的研究，大多停留在现象描述和特征总结，未能提出如何将发现转化为可操作的教育资源；而探索 AI 应用的研究，则较少扎根于社交媒体海量的、真实的青少年非正式话语体系。

正因此，本研究的切入点恰好呼应了这一断层：通过结合大数据与大语言模型技术，系统性地挖掘与分析 Bilibili 平台上青少年用户的真实问题，并将其转化为高质量的标准化问答数据集，再以此为基础对模型进行微调和评估。这不仅是对国内青少年数字健康行为的深度洞察，更是将前沿 AI 技术与真实社会需求相结合的创新实践，力图为优化中国青少年生殖健康信息的传播策略提供科学依据。

1.3 应用前景

本研究的应用前景广阔且具有现实意义。通过将前沿的大语言模型技术与真实的社交媒体用户数据相结合，本课题不仅在理论方法上具有创新性，更在实践应用层面展现出巨大潜力，相关成果有望在未来青少年生殖健康教育、公共卫生政策制定及人工智能健康应用等多个领域发挥积极作用。

研究成果能够为政府及公共卫生部门制定更精准、有效的青少年健康教育政策提供坚实的数据支撑。传统的健康需求调查往往依赖问卷，存在样本偏差和应答者社会期许效应等局限。本研究通过对数百万条真实、自发的网络评论进行挖掘与分类，能够动态、规模化地揭示当代青少年在生殖健康方面的真实困惑、核心关切与知识盲区。这份来自一线的“数据画像”可以帮助决策者精准定位教育的重点与难点，从而制定出更具针对性的教育大纲与干预策略，推动公共卫生资源从普适性宣授向精准化建言的策略转变。

本研究亦可为医疗卫生专业人员及健康科普创作者参与线上健康传播提供科学指南与实用工具。通过系统分析青少年在 Bilibili 平台上的互动行为与提问偏好，研究可以揭示何种内容形式、叙事风格和互动模式更受年轻用户欢迎。同时，研究产出的高质量、结构化生殖健康问答数据集，本身就是一个宝贵的知识库。医疗专业人士可以此为参考，创作出更贴近青少年需求的科普作品，有效回应青少年群体的核心关切，进而提升专业内容在社交媒体环境中的传播力与影响力，积极对抗网络健康谣言的传播。

研究的成果也有望直接推动智能化健康教育工具的开发与应用，并为社交媒体平台优化内容生态提供科学依据。研究不仅构建了问答数据集，更进一步利用该数据集对大语言模型进行微调。这个经过领域知识增强的垂域优化模型，为开发下一代青少年健康智能问答系统的理想内核提供了参照。包括但不限于被部署为网站、APP 或小程序中的 7x24 小时在线的“AI 健康助手”，为青少年提供一个私密、安全、准确且富有同理心的提问渠道，有效解决他们因害羞或隐私顾虑而不敢求助于家长或老师的难题。对于 Bilibili 等平台而言，本研究的发现有助于其优化推荐算法，优先推送科学、权威且高互动性的健康内容。

综上，本课题研究致力于将海量、零散的用户生成信息，转化为精准、优质的结构化知识资源，并最终落地为智能化的健康服务。这不仅为解决当前青少年生殖健康教育的痛点提供了创新方案，更能助力我国青少年健康教育事业朝向精准化、智能化和人性化的方向迈进。

参考文献

- [1] PATTON G C, SAWYER S M, SANTELLI J S, 等. Our future: a Lancet commission on adolescent health and wellbeing[J/OL]. The Lancet, 2016, 387(10036): 2423-2478. DOI:10.1016/S0140-6736(16)00579-1.
- [2] WORLD HEALTH ORGANIZATION. Adolescent pregnancy[EB/OL]. [2025-09-15]. <https://www.who.int/news-room/fact-sheets/detail/adolescent-pregnancy>.
- [3] 张艺珊, 张雪松, 李晓宇, 等. 青少年生殖健康现状[J]. 中国计划生育和妇产科, 2020, 12(4): 4-6.
- [4] ZOU Z, DONG Y, SONG Y, 等. Strengthening sexual and reproductive health education for children and adolescents in China[J/OL]. The Lancet Child & Adolescent Health, 2023, 7(9): 603-605. DOI:10.1016/S2352-4642(23)00138-4.
- [5] CHANDRA-MOULI V, NEAL S, MOLLER A B. Adolescent sexual and reproductive health for all in sub-Saharan Africa: a spotlight on inequalities[J/OL]. Reproductive Health, 2021, 18(S1): 118, s12978-021-01145-4. DOI:10.1186/s12978-021-01145-4.
- [6] QIAO J, WANG Y, LI X, 等. A Lancet Commission on 70 years of women's reproductive, maternal, newborn, child, and adolescent health in China[J/OL]. The Lancet, 2021, 397(10293): 2497-2536. DOI:10.1016/S0140-6736(20)32708-2.
- [7] BHANA D, AGGLETON P, MIEDEMA E, 等. Beyond controversy – International perspectives on sexual and reproductive health education[J/OL]. Health Education Journal, 2024, 83(8): 821-829. DOI:10.1177/00178969241297016.

- [8] 赵芮, 张磊, 富晓星, 等. 中国 11 省市青少年性与生殖健康知识、态度及行为调查[J/OL]. 中国公共卫生, 2019, 35(10): 1330-1338. DOI:10.11847/zgggws1124531.
- [9] GABARRON E, WYNN R. Use of social media for sexual health promotion: a scoping review[J/OL]. Global Health Action, 2016, 9(1): 32193. DOI:10.3402/gha.v9.32193.
- [10] GUSE K, LEVINE D, MARTINS S, 等. Interventions Using New Digital Media to Improve Adolescent Sexual Health: A Systematic Review[J/OL]. Journal of Adolescent Health, 2012, 51(6): 535-543. DOI:10.1016/j.jadohealth.2012.03.014.
- [11] SEWAK A, YOUSEF M, DESHPANDE S, 等. The effectiveness of digital sexual health interventions for young adults: a systematic literature review (2010–2020)[J/OL]. Health Promotion International, 2023, 38(1): daac104. DOI:10.1093/heapro/daac104.
- [12] CHEN J, WANG Y. Social Media Use for Health Purposes: Systematic Review[J/OL]. Journal of Medical Internet Research, 2021, 23(5): e17917. DOI:10.2196/17917.
- [13] UHAWENIMANA T C, MUSABWASONI M G S, NSENGIYUMVA R, 等. Sexuality and Sexual and Reproductive Health Depiction in Social Media: Content Analysis of Kinyarwanda YouTube Channels[J/OL]. Journal of Medical Internet Research, 2023, 25(1): e46488. DOI:10.2196/46488.
- [14] 陈明红, 黄嘉乐, 连晓丽. 弹幕视角下健康视频需求主题特征及其对视频播放的影响[J/OL]. 情报杂志, 2023: 148-155. DOI:10.3969/j.issn.1002-1965.2023.04.021.
- [15] SUAREZ-LLEDO V, ALVAREZ-GALVEZ J. Prevalence of Health Misinformation on Social Media: Systematic Review[J/OL]. Journal of Medical Internet Research, 2021, 23(1): e17187. DOI:10.2196/17187.
- [16] 郑杰心. 健康科普类短视频的传播策略研究 ——以抖音为例[J/OL]. 电视技术, 2021, 5(45): 34-37. DOI:10.16280/j.videoe.2021.05.010.
- [17] THIRUNAVUKARASU A J, TING D S J, ELANGO VAN K, 等. Large language models in medicine[J/OL]. Nature Medicine, 2023, 29(8): 1930-1940. DOI:10.1038/s41591-023-02448-8.
- [18] AYERS J W, POLIAK A, DREDZE M, 等. Comparing Physician and Artificial Intelligence Chatbot Responses to Patient Questions Posted to a Public Social Media Forum[J/OL]. JAMA Internal Medicine, 2023, 183(6): 589-596. DOI:10.1001/jamainternmed.2023.1838.
- [19] UNESCO. Switched On: Sexuality Education in the Digital Space[R]. UNESCO Paris, 2020.
- [20] UNICEF, OTHERS. The opportunity for digital sexuality education in East Asia and the Pacific: Desk-based Review: UNICEF EAPRO Report (Bangkok)[R]. 2019.
- [21] ALKHODAIR R, ALFAWZAN A, ALHARTHI S A, 等. Assessing the Quality and Accuracy of Syphilis-Related Content on TikTok and YouTube: A Comprehensive Analysis[J/OL]. Sexually Transmitted Diseases, 2025, 52(2): 81-86. DOI:10.1097/OLQ.0000000000002090.
- [22] ABACHA ASMA BEN, MRABET YASSINE, SHARP MARK, 等. Bridging the Gap Between Consumers' Medication Questions and Trusted Answers[J/OL]. Studies in Health Technology and Informatics, 2019[2025-09-15]. <https://www.medra.org/servlet/aliasResolver?alias=iospressISBN&isbn=978-1-64368-002-6&spage=25&doi=10.3233/SHTI190176>. DOI:10.3233/SHTI190176.
- [23] DODIYA T, JAIN S. Question classification for medical domain Question Answering system [C/OL]//2016 IEEE International WIE Conference on Electrical and Computer Engineering (WIECON-ECE). 2016: 204-207[2025-09-15]. <https://ieeexplore.ieee.org/abstract/document/8009118>. DOI:10.1109/WIECON-ECE.2016.8009118.
- [24] NORI H, KING N, MCKINNEY S M, 等. Capabilities of GPT-4 on Medical Challenge Problems[A/OL]. arXiv, 2023[2025-09-15]. <http://arxiv.org/abs/2303.13375>. DOI:10.48550/arXiv.2303.13375.
- [25] 陈功, 郑晓瑛, 晓瑛 郑. 中国青少年生殖健康可及性调查基础数据报告[J]. 人口与发展, 2010(3): 2-16.
- [26] 夏瑞宏, 陈佳俊, 瞿先国. 中学生对利用网络开展性教育的认知及影响因素分析[J/OL]. 中国学校卫生, 2022(43(4)): 518-521. DOI:10.16835/j.cnki.1000-9817.2022.04.009.
- [27] 赵智美. 抖音平台医学科普类健康传播短视频研究[J/OL]. Journalism and Communications, 2023, 11: 424. DOI:10.12677/JC.2023.113065.
- [28] GUO H, NA X, HOU L, 等. Classifying Chinese Questions Related to Health Care Posted by Consumers Via the Internet[J/OL]. Journal of Medical Internet Research, 2017, 19(6): e220. DOI:10.2196/jmir.7156.
- [29] YANG S, ZHAO H, ZHU S, 等. Zhongjing: Enhancing the Chinese Medical Capabilities of Large Language Model through Expert Feedback and Real-World Multi-Turn Dialogue[J/OL]. Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(17): 19368-193

2 研究目标、内容和拟解决的关键问题

2.1 研究目标

本课题立足于 Bilibili 平台上与青少年生殖健康相关的视频评论、评论回复与弹幕内容，以大数据分析与大语言模型技术为依托，拟实现以下研究目标：

(1) 青少年生殖健康问题分类分析研究

基于海量的评论文本，对青少年提出的隐性或显性健康问题进行识别与主题归类，明确其在避孕、流产、性传播疾病防控、青春期教育等方面的核心关注点和信息需求，为后续研究提供基础框架。

(2) 问答生成与数据集构建

在分类基础上，利用大语言模型对用户提出的问题进行改写，使其表达更为正式、规范和科学，从而形成适合教育场景使用的标准化问题集合。围绕标准化问题，结合大语言模型生成答案并辅以人工修订，形成高质量的生殖健康问答数据集，为后续模型优化奠定数据基础。

(3) 模型微调与效果验证

以开源大模型为底座，利用构建的问答数据集进行微调；通过与通用大模型的对比，重点验证微调后模型在准确性、完整性、表达性与实用性等维度上的改进效果，从而评估大语言模型在青少年生殖健康教育问答任务中的适用性和价值。

2.2 研究内容

本课题的研究内容主要包括以下三个方面：

(1) 评论与问题提取

研究将对 Bilibili 平台上与生殖健康相关的视频评论、弹幕及回复进行系统采集与清洗，并在此基础上建立语义识别与编码机制，从复杂多样的自然语言表达中自动筛选出具有“问题型”特征的内容。为确保数据的准确性与科学性，研究将引入人工复核与纠偏，对自动化提取的结果进行补充和修正，从而形成较为完整且高质量的初步问题集合。

(2) 青少年生殖健康问题分类分析研究

在初步问题集合的基础上，研究将利用主题建模、语义聚类及人工校正等方法，对问题进行系统分类，建立覆盖避孕方式、人工流产、青春期教育、性病防控等核心维度的分类框架。通过定量分析各类问题的分布情况和特点，揭示青少年在不同主题下的关注重点与知识缺口，为后续的问答生成和模型优化提供有针对性的方向。

(3) 问题规范化与问答生成

在分类结果的支撑下，研究将借助大语言模型对用户所提出的问题进行正式化与科学化改写，使其更加规范、清晰和符合教育传播的语境。同时，利用大语言模型生成与优化对应答案，形成问题—答案（Q&A）对，并结合人工审核与修订，确保所产出内容的准确性和适用性。通过这一

过程，逐步构建覆盖避孕方式、人工流产、性教育、性病防治等核心主题的标准化生殖健康问答数据集，为后续的模型微调与知识传播提供可靠的内容资源。

(4) 模型微调与效果评估

获得高质量问答数据集后，研究将选择适合的开源大语言模型（如 Qwen 或 LLaMA 系列）开展指令微调实验，以提升模型在生殖健康问答场景中的表现。不仅将通过 ROUGE、BLEU 等自动化指标来评估模型输出的语言质量，还将结合人工评估，从准确性、完整性、表达性和实用性等多个维度进行综合对比，以全面验证模型在微调前后的性能改进效果。

2.3 拟解决的关键问题

围绕青少年生殖健康教育中“非正式信息如何高效转化为标准化知识资源”的核心挑战，本研究拟重点解决以下问题：

(1) 如何从非结构化评论中准确识别并提取具有问答价值的问题？

研究需要结合关键词识别与语义检索等技术，并引入人工校对机制，确保提取内容的科学性与代表性。

(2) 如何对识别出的健康问题进行合理分类和多维度分析？

针对提取出的初步问题集合，研究需要明确分类标准与主题框架，探索利用主题建模、语义聚类 and 人工审核相结合的方法，对青少年生殖健康问题进行系统化分层。此过程既要保证分类的科学性与覆盖面，又要揭示不同类别背后的知识缺口和用户需求差异。

(3) 如何提升用户原始问题的规范化程度与教育传播价值？

在分类过程的基础上，研究进一步利用大语言模型对问题进行标准化重写，确保其表达符合学术与医学规范，并符合教育传播需求，兼顾科学性、清晰性与面向青少年群体的可理解性，从而形成具有规范性的标准化问题集合。

(4) 如何构建高质量的问答数据集并保证其科学性？

利用大语言模型生成答案时需要解决自动生成内容可能存在的不严谨与偏差，需结合人工修订和专家审核提升数据完整性与权威性，确保问答对能够真实、准确地服务于健康教育。

(5) 微调后的模型在健康教育问答中的表现是否优于通用大模型？

需要通过多维度指标——自动化评价与人工评分相结合的方式，系统验证微调模型是否在准确性、完整性、表达性和实用性方面较通用模型有所提升，从而判断其在青少年生殖健康教育中的应用前景与价值。

3 研究方法、技术路线、实验方案及可行性分析

3.1 研究方法

本课题将综合采用多种研究方法，确保研究具有科学性与可靠性：

(1) 网络文本采集与挖掘

利用分布式爬虫技术，系统采集 Bilibili 平台 2016 年 9 月至 2024 年 6 月间与生殖健康相关的高热度视频及其评论、回复与弹幕，构建原始文本语料库。

(2) 问题识别与规范化处理

通过关键词过滤、语义匹配和规则识别，对评论和弹幕中潜在的健康问题进行自动化提取，初步形成问题集合。

(3) 青少年生殖健康问题分类分析

在完成初步问题识别后，利用主题建模、语义聚类 and 人工修订相结合的方法，对问题进行系统分类，建立涵盖避孕方式、人工流产、青春期教育、性病防治等主要主题的分类框架，并分析不同类型问题的数量分布、表达形式及知识缺口。

(4) 问题规范化与问答生成

利用大语言模型对问题进行正式化、科学化重写，确保其表达规范，利于健康教育场景应用。在问题规范化的基础上，通过大语言模型生成与优化答案；结合人工审核，形成结构化的问答对（Q&A），从而建立覆盖多类生殖健康主题的高质量问答数据集。

(5) 大模型微调与性能对比

选择合适的开源大模型作为底座，采用指令微调（Instruction-tuning）方法，利用构建的问答数据集进行模型微调；对比微调前后的模型在准确性、完整性、表达性和实用性等维度的表现。

(6) 效果评估与统计分析

将自动化指标与人工评估结合，综合考察不同模型在生殖健康问答任务上的效果，量化分析微调对模型性能提升的贡献。

3.2 技术路线

本研究遵循“数据采集—数据处理—问题识别—问题分类—问题规范化与问答生成—问答数据集构建—模型微调—效果评估”的总体技术路线，具体步骤如下：

(1) 数据采集

搭建分布式爬虫框架，采集相关视频及评论、弹幕、用户互动等数据；初步筛选与生殖健康相关的内容。

(2) 数据处理与问题识别

使用 jieba 等中文分词工具结合语义检索方法，对评论文本进行清洗、去重、去噪与主题筛选，自动识别评论中的疑问表达，生成候选问题集合。

(3) 问题分类与专题分析

在候选问题集合的基础上，结合主题建模、语义聚类与人工修订建立分类体系，涵盖多个核心生殖健康主题，提取显性或隐性问题，并对各类问题的比例、表述方式和需求特征进行统计和专题分析。

(4) 问题规范化与问答生成

利用大语言模型（如 Qwen2.5-32B）对提取出的问题进行正式化重写，确保其语义清晰、科学规范；在此基础上自动生成答案，并通过人工修订保障内容的准确性与完整性。

(5) 问答数据集构建

将规范化问题与对应答案组织为 Q&A 对，按照避孕、流产、性教育、性病预防等主题标签分类，形成结构化问答数据集。

(6) 模型微调与效果评估

在选定的开源大语言模型基础上进行指令微调，提升其对生殖健康教育类问题的适应性，并与通用模型进行对比；通过自动化与人工评估相结合的方法，验证微调前后模型在青少年生殖健康教育任务中的改进效果。

3.3 实验方案

3.3.1 数据收集

本研究基于 Bilibili 平台，系统选取 2016 年 9 月至 2024 年 6 月期间上线且单个视频观看次数大于等于 100,000 次的与生殖健康相关的视频作为研究对象。为实现高效、全面的数据抓取，计划依托分布式网络爬虫工具，自动采集目标视频的基础信息，包括标题、标签、简介、发布时间及创作者背景等。同时，将全面获取目标视频下的用户评论（含楼中楼）、评论回复、弹幕内容及点赞、分享、收藏等互动行为数据。数据抓取将采取定期更新的方式，以保证对平台热门内容的动态覆盖和研究样本的代表性与时效性。

3.3.2 样本筛选

根据领域专家建议，遴选出 18 个生殖健康相关关键词作为初筛标准。这些关键词不仅涵盖“避孕”“性教育”“月经”“流产”“艾滋病”“安全套”等高频核心主题，还结合网络流行语与同义表述进行语义扩展。研究将通过自动化脚本在视频标题、简介与评论内容中进行多轮关键词检索，从而初步筛选出符合相关性的样本。为保证数据的科学性与针对性，研究将引入人工复查机制，对筛选结果进行逐一核查，剔除主题不符或低相关度的样本，最终形成研究所需的核心数据集。

3.3.3 数据预处理

实验数据将进行严格的预处理操作，以确保语料的规范性与有效性。此环节包括数据去重、异常值识别、文本清理与标准化等步骤。研究将使用 jieba 等成熟的中文分词工具对评论和弹幕进行分词处理，去除无意义字符、广告及灌水信息，并统一表情符号与同义词表达，确保语言表述的一致性。针对大规模数据，研究还将部署自动化脚本对重复样本、异常文本及无效数据进行清理，从而保证下游问题分类与分析、规范化和问答生成任务的准确性和可靠性。

3.3.4 人工审核与质量控制

为保证数据集质量，研究将引入人工审核。所有样本将由两名经过培训的研究人员独立完成主题归类、内容标签标注及创作者背景判断，标注内容涵盖视频主题类型、信息属性、以及创作者是否具有医学或科普专业背景等多个维度。当审核者之间存在分歧时，将邀请第三方领域专家进行裁定，确保结果的权威性与一致性。研究将定期对标注一致性进行检测，对于一致性偏低的样本进行复查与流程优化。通过上述机制，确保后续问题分类分析和构建问答数据集在科学性和教育价值上的高质量。

3.3.5 问题分类与分析

在经过预处理和人工审核后的文本中，研究将对已识别的问题进行系统分类。首先利用自动化方法（Latent Dirichlet Allocation, LDA 主题模型、语义聚类等）对问题进行初聚合，再结合人工复核和专家判断形成最终分类框架。分类结果将揭示青少年在不同健康主题下的主要问题类型，并通过统计与专题分析识别高频问题和知识盲区，为规范化表述与问答生成提供方向。

3.3.6 问题规范化与问答生成

结合分类结果，研究将重点开展问题提取与规范化。通过语义识别与规则匹配方法自动识别评论中的疑问表达，并将其转化为候选问题集合。利用先进的大语言模型（如 Qwen2.5-32B）对这些问题进行正式化与科学化的改写，提升问题在教育场景中的清晰度和传播价值。在规范化问题的基础上，进一步借助大语言模型生成对应答案，并结合人工修订，确保回答的准确性、完整性和适用性。最终，构建覆盖避孕、性教育、性病防治等主题的标准化问答对(Q&A)，形成结构化的生殖健康问答数据集。

3.3.7 模型微调与效果评估

问答数据集构建完成后，研究将选择开源大模型作为基底，采用指令微调的方法对模型进行适配，使其能更加准确地应对青少年生殖健康领域的问答需求。为验证微调的有效性，保留通用版本模型作为对照组，通过两类模型在相同问答任务下的表现进行比较。性能评估将采用自动化指标（如 BLEU、ROUGE 等）与人工评估相结合的方式。人工评估拟从准确性、完整性、表达性与实用性四个维度对模型输出进行考察，从而全面衡量微调过程对模型性能提升的价值。

3.4 可行性分析

3.4.1 技术可行性

网络爬虫、中文自然语言处理及大语言模型微调方法均已成熟，本人具备丰富的文本挖掘与模型应用经验，完全能够支持研究实施。

3.4.2 数据可行性

Bilibili 平台具有公开可获取的大规模评论与弹幕数据，覆盖面广且语料丰富，能为研究提供真实可靠的用户生成内容。

3.4.3 伦理与合规可行性

所有数据均来自公开渠道，将在采集与处理过程中进行匿名化，严格删除可识别个人身份的信息，确保数据合规与隐私保护。

3.4.4 资源可行性

依托高校与课题组的技术与硬件资源，包括高性能计算平台、专业研究人员及跨学科协作能力，研究具备扎实的软硬件条件与专业支持。

4 特色或创新之处

本课题紧密结合中国青少年在 Bilibili 平台获取生殖健康知识的现实场景，聚焦社交媒体评论、评论回复与弹幕所承载的真实需求与非正式表达，具有如下突出特色和创新点：

4.1 研究视角创新

以往研究多集中在对用户评论的语言特征、情绪反应或信息传播模式的分析，较少深入探讨如何将评论内容转化为可直接服务于健康教育的知识资源。本研究首次将 Bilibili 平台上的青少年评论作为问题来源，不仅关注其内容本身，还聚焦如何通过分类、规范化与知识转化将零散、口

语化的用户表达转化为规范化问题以及结构化问答资源，为平台健康传播与学术研究提供了新的视角。

4.2 方法路径创新

本研究在研究方法上建立了“问题提取—问题分类—问题规范化—问答生成—人工修订—模型微调”的系统方法链。在“问题分类”这一环节，创新性地在规范化处理之前引入主题聚类与多维度分析，不仅可以揭示青少年在避孕、流产、性传播疾病防治、青春期教育等方面的不同关注重点，还能后续问答生成提供明确内容导向。通过大语言模型进行非正式问题的科学化重写，并生成初步答案，再辅以人工审核，最终形成高质量的问答对数据集。以此为基础，对开源大模型进行领域微调，验证其性能变化。该方法体系创新性地把大语言模型同时作为数据加工工具与研究对象，实现了从真实用户评论到可用问答资源、再到优化智能模型的完整链路。

4.3 数据规模与质量的积累优势

课题依托 2016 年至 2024 年间 Bilibili 平台相关视频的评论与弹幕，覆盖数百万条用户生成内容，数据量丰富，样本多样化。研究将在此基础上构建国内首次较全面的青少年生殖健康问答数据集。通过分类与统计分析，不仅能描绘出青少年在不同健康主题下的问题分布，还能揭示潜在的知识盲区。同时，通过严格的人工审核与专家把关机制，保证数据不仅在规模上具备代表性，更在质量上符合科学性和教育性要求。

4.4 模型应用的创新

研究不仅停留在数据收集和内容处理层面，还将尝试在大语言模型的教育应用上实现突破。研究在问答数据集基础上，对开源大模型开展指令微调，并设置通用模型作为基线进行性能对比。通过实验检验，验证微调后模型在生殖健康教育情境下的性能的提升，进而助力于探索数据驱动优化的途径。以上尝试有助于探索大语言模型在公共健康教育领域的应用实践，推动其从实验型技术走向针对性应用。

5 研究计划及预期进展

本研究聚焦于中国青少年在 Bilibili 平台获取生殖健康信息的真实需求与互动表达，依托大数据采集、自然语言处理与大语言模型技术，建立一套涵盖评论问题识别、问题分类分析、问题规范化、问答生成与模型微调评估的研究体系。课题不仅力求揭示青少年在网络空间中对生殖健康知识的关注点、分类分布与表达方式，还将推动用户生成内容向结构化教育资源的转化，促进健康教育内容的标准化、智能化和精准化，最终服务于提升青少年生殖健康素养与公共健康传播能力。

本研究的预期成果包括：发表一篇论文，系统展示本课题在用户评论转化、问题分类方法、问答数据集构建及模型微调方法等方面的创新性与学术价值；构建并发布青少年生殖健康问答模型，为教育机构、公共卫生部门和平台运营方提供可直接应用的工具与数据支撑。研究还将开放部分技术文档与规范化问答数据集，帮助后续相关研究与政策制定，推动我国青少年生殖健康教育事业的科学创新与持续发展。

ID	任务名称	开始	完成	持续时间 (天)
1	文献综述	2025/12/25	2026/1/15	21
2	数据采集框架完善	2026/1/16	2026/2/1	17
3	数据集构建与预处理	2026/2/1	2026/3/1	28
4	原始数据清洗与规范化	2026/2/1	2026/2/10	10
5	问题分类与分析	2026/2/11	2026/2/20	10
6	问题规范化处理、问答生成与人工审核	2026/2/21	2026/3/1	9
7	模型微调与效果评估	2026/3/2	2026/3/19	17
8	学术论文撰写	2026/3/20	2026/4/7	28
9	论文修改、专家评审、毕业答辩准备	2026/4/8	2026/5/12	34
10	毕业答辩	2026/5/13	2026/6/16	34

表 5-1 研究计划表

6 已具备的条件、尚缺少的条件和拟解决的途径

为了确保研究顺利开展，有必要对目前研究已具备的条件、尚缺少的资源或能力，以及拟采取的解决途径进行全面评估。

6.1 已具备的条件

(1) 完整的 Bilibili 平台数据资源

目前已系统采集并整理了 2016 年至 2024 年期间与青少年生殖健康相关的 Bilibili 视频、评论、回复与弹幕数据。该数据集规模大、覆盖面广，不仅包含海量的用户生成信息，还保留了互动行为数据。经过初步清洗与筛选，目前已获得结构化整理后的 Excel 表格（见图 6-1），涵盖评论 ID、时间、文本内容（部分脱敏）、初步标签及有效性标注等核心字段。这些成果表明数据获取与处理流程具备可行性，为后续问题提取、规范化和问答生成奠定了基础。

id	search_site	URL	Video_ID	Title	Bullets_Count	Bullet_Videotime	Content	Net_Postt	Tag	Comment_ID
4780	安全套		BV1r54y167z	【性知识】小心得性病！安全套/避孕套怎么选？			那么我戴到底只到三分之二咋办		安全套	BV1r54y167z
4391	体外射精		BV1eN4y147z	“射精前液体”是什么东西？			请问一下~我感觉这个液体我流的太多了，我女朋友常说我不流，真的很久没看到她，一		生殖健康科	BV1eN4y147z
3490	体外射精		BV1eN4y147z	“射精前液体”是什么东西？			医生，我想问一下，我有痔疮，然后吃了地奥司明片吃了大概有两盒，但是我发现这个里		生殖健康科	BV1eN4y147z
3968	避孕套		BV1eK411U7z	“水田”才是恋爱关键？选对避孕套			大号的3001有吗，我没找到过		安全套	BV1eK411U7z
2059	避孕套		BV1eK411U7z	“水田”才是恋爱关键？选对避孕套			你用过的吗？没用过那怎么知道效果好不好？		安全套	BV1eK411U7z
2005	体外射精		BV1JH4y1H7z	《男性射精的速度有多快？			夫妻生活，不是越持久越好吗？		生殖健康科	BV1JH4y1H7z
4796	避孕套		BV1EU411F7z	《爱情请用力拥抱》与婚检积极较			玻尿酸这个东西会不会因为玻尿酸太厚然后在做的过程中脱落嘛？		生殖健康科	BV1EU411F7z
181	避孕	https://www.BV1uk4y1y7z	【你知道】为什么用了避孕套还会怀		4853	05:03	不是把蛋蛋割掉？	08-25 18:11	安全套	
190	避孕	https://www.BV1uk4y1y7z	【你知道】为什么用了避孕套还会怀		4853	03:55	没有给男人吃的避孕药吗？	08-25 23:51	安全套	
203	避孕	https://www.BV1uk4y1y7z	【你知道】为什么用了避孕套还会怀		4853	04:45	男的这就跳脚啦？	10-11 23:11	安全套	
201	避孕	https://www.BV1uk4y1y7z	【你知道】为什么用了避孕套还会怀		4853	03:19	男性避孕药在一般药店买得到？	08-26 11:11	安全套	
192	避孕	https://www.BV1uk4y1y7z	【你知道】为什么用了避孕套还会怀		4853	04:34	男性避孕药不就这了吗	08-26 00:22	安全套	

图 6-1 数据爬取、清洗初步结果

(2) 成熟的文本处理与模型应用经验

已搭建完善的中文文本预处理流程，能够高效实现大规模语料的去重、清洗与标准化。在预实验中，约 5000 条原始评论经去重、噪声过滤后，保留 3780 条有效评论，该处理流程具有较高的实用性。本人熟悉大语言模型的应用与微调方法，已具备利用模型开展文本生成与问答优化的技术能力。

(3) 初步研究成果为方向提供参考

通过对清洗后评论的探索性分析，已识别出青少年用户在评论中集中关注的核心话题，如避孕方法、非意愿妊娠处理、性病预防与情感困惑等（见图 6-2、图 6-3）。在小规模样本上，已初

步尝试将评论问题输入大语言模型，模型能够实现同义问题改写和基础性答案生成，并在准确表达与逻辑连贯性上表现出可行性。这些预实验结果验证了研究方法的可操作性，并指明了下一阶段大规模实验的研究重点。



图 6-2 视频搜索关键词词云




图 6-3 评论主题分类

(4) 跨学科团队支持

课题组成员涵盖公共卫生、医学信息学、传播学及数据科学等多学科背景，既能从健康教育与传播的角度把握研究方向，也能在模型算法与数据处理环节提供技术支持。跨学科的团队构成确保了课题在理论研究和技術实践两方面均具备充足条件。

6.2 尚缺少的条件

- (1) 医疗与教育专业人员的深度参与
- 当前课题组成员的公共卫生与数据科学背景较为突出，但在医学专业内容审核与青少年健康教育实践指导方面力量不足，亟需引入更多医学专家、健康传播学者与一线教育从业者，帮助确保问答数据集的科学性与实用性。
- (2) 更大规模的纵向与多样化数据
- 现有数据采集主要以横断面为主，虽已覆盖多个年度，但缺乏持续动态的纵向跟踪与多批次更新，难以全面展现青少年健康信息需求及表达方式的长期演变。

(3) 模型训练所需的计算资源

本课题计划在开源大模型基础上进行微调，但目前计算硬件资源相对有限，可能影响更大规模实验的进展和效率。

6.3 拟解决的途径

(1) 加强跨界合作，提升数据科学性

主动联系医院、公共卫生机构与健康教育机构，邀请医学专家和一线教育人员以顾问或合作研究员的形式参与项目，把关问答数据集答案的科学性，并提升研究结果在教育实践中的指导意义。

(2) 建立动态数据采集与更新机制

未来将通过定期爬取目标视频及其评论，建立时序化数据库，从而观察青少年健康话题需求与提问方式的长期变化。同时，考虑在条件成熟时扩展至其他社交平台（如微博、抖音），形成更具对比性与普适性的研究样本。

(3) 争取技术与资源支持

申请学校和科研平台的计算资源支持，并探索使用开源高效模型微调方法，以降低硬件压力。必要时，拟通过合作实验室或云平台共享算力资源，确保模型训练与测试环节顺利进行。

本科生毕业论文（设计）开题报告评定表

指导教师意见	指导教师签名：年 月 日
系审核意见	系主任签名：年 月 日
院审核意见	院长签名：年 月 日
备注	