

各位老师好，我是周子轩，我的毕业设计题目是“基于大语言模型的社交媒体青少年生殖健康评论分类分析与问答生成研究”。指导老师是黄若尘老师。**2** 报告分背景、方法、成果与展望四部分 **3** 首先，是研究背景与意义 **4** 关于**本研究的背景**。青少年生殖健康问题在全球范围内都十分严峻。世卫组织和《柳叶刀》的报告都指出，相关问题存在被长期忽视的情况。中国也面临同样的挑战，包括青少年非意愿妊娠、人工流产及性病感染率**持续上升**的严峻现状。不论是全球视角还是中国的现状，都反映出一个核心矛盾：那就是青少年日益严峻的健康风险与当前**亟需加强**的生殖健康教育之间的鸿沟。**5** **传统教育**面临文化敏感性高、覆盖面不足和效果不佳的困境，于是青少年转向了B站这类更便捷、匿名的社交平台，为我们提供了一个**洞察**他们**真实困惑**的天然“问题语料库”。但这个库藏的内容良莠不齐，因此，如何从海量、非结构化的文本中**挖掘价值**，并转化为科学、规范的知识资源，成为关键挑战。**6** 本研究兼具理论与实践价值。理论上，聚焦用户互动端，创新匿名言论挖掘的需求识别路径，探索大模型在健康教育中的应用模式；实践上，为精准教育、平台治理与智能问答系统提供数据支撑。

7 **研究内容与方法** **8** **研究目标及内容**主要为四项：第一，从B站海量评论中，筛选出用户的真实问题。第二，对问题进行分类和定量分析，揭示青少年的关注焦点。第三，利用大模型生成高质量的问答对，构建一个标准数据集。第四，用该数据集去微调一个模型，并评估其回答专业问题的能力。**9** **技术路线**是：从B站采集数据，经数据清洗等处理后识别并分类用户问题，再利用大模型生成高质量的问答集，并最终用它来微调和评估专用的大语言模型。**10** 数据源于B站满足视频筛选标准的743个视频，最终经过数据预处理和问题提取后得到2767条有效问题。**11** 利用大模型将口语化问题规范化重写和答案生成，答案生成遵循科学准确、通俗易懂等六大原则。**12** 然后是人工修订与专家审核，专家从六个维度对答案进行打分评估。**13** 打分表格是六个维度的3点Likert量表，1-3分定义如表所示。**14** 为实现数据集的大规模打分评估，研究择选了5个主流大语言模型在抽取的数据集样本上进行打分，通过kappa指标判断与专家的相似度，遴选确认DeepSeek-V3.2为自动化评估模型，最终构建了2767条问答对作为完整问答数据集。**15** 如表是5个参评模型以及遴选得到的评估用模型与专家打分的kappa相似度指标的结果。**16** 微调选用了Qwen2.5与Qwen3系列六款模型。**17** 6款模型统一采用了LoRA参数高效微调的方法。

18 **下面是研究结果**。**19** 对问题进行主题分类后，发现青少年需求呈现“头部集中、长尾分布”特征。安全套与生殖健康科普两类占比近2/3，反映出青少年对基础知识和实用工具的极度渴求。体外排精、安全期避孕等低效方法讨论热度高，反映出青少年侥幸心理的普遍；人工流产等高风险话题互动强烈，但专业知识供给严重缺位。此外，节育器、女用安全套等小众话题亦有真实需求，说明了青少年需求的多元。**20** 模型效果从ROUGE自动化指标和六维度AI打分两方面评估。**21** 统计检验显示，绝大多数维度p值小于0.001，微调效果高度可靠。‘准确性’与‘仅提供必要信息’的中位数差异达1分，实现整档跃升。值得注意的是，Qwen2.5系列中1.5B和3B小模型的ROUGE提升未达显著，而Qwen3-1.7B小参数模型却能显著提升，说明架构代际差异是比参数规模更关键的因素。此外，‘易于理解’维度基线已接近满分，微调的边际增益有限**22** 以微调效果最显著的Qwen3-4B为例，细分到主题层面，人工流产提升0.619分，体外排精提升0.476分，提升幅度向常规高频议题递减，说明数据集在不同主题上的覆盖较为充分且均衡。在典型案例中，微调后模型纠正了基模型将‘中晚期终止妊娠’错误描述为‘常规选择’的问题，准确给出医学指征。但模型仍存在能力盲区：面对男性避孕针等前沿未定论议题时易混淆研究进展与既有知识；面对二手避孕套等伪概念提问时缺乏批判性反驳，倾向于迎合式演绎，存在安全隐患。

23 **总结与展望** **24** 本研究的核心结论如下：首先，青少年需求呈‘头部集中、长尾分布’，基础科普与安全套是主要讨论话题，高风险议题认知误区普遍。研究也证实用户评论能有效反映传统问卷难以捕捉的敏感困惑与情感诉求。大模型配合人工审核可规模化产出高质量问答数据。第四，领域微调显著提升了模型专业性，但面对前沿议题和伪概念时，幻觉风险仍需关注。创新点体现在四个维度：研究对象上，首次深入B站青少年真实评论；方法路径上，构建了从原始数据到优化AI模型的完整闭环；数据资源方面，产出国内首个源于社交媒体真实场景的青少年生殖健康标准化问答数据集；模型应用方面，探索了中文青少年健康教育垂域大模型的评估方法论框架。

25 本研究存在三方面局限：数据限于B站单一平台，且偏向高播放量视频；大模型幻觉问题未完全根除；人工审核与评估受样本量约束。未来将从四个方向深化：拓展至抖音等多平台开展比较研究；引入RAG技术，将模型与权威医学知识库动态链接；探索多轮对话与个性化交互；持续扩充数据集，以增强模型鲁棒性与安全性。